UNIVERSIDADE REGIONAL DE BLUMENAU
CENTRO DE CIÊNCIAS EXATAS E NATURAIS
CURSO DE CIÊNCIA DA COMPUTAÇÃO

Processamento de Linguagem Natural — 2026/2

Trabalho da Unidade 3

Sinopses e críticas de filmes do TMDB: representações textuais e tarefas de PLN

Equipe: Kaike Ventura Tuerpe, Luana Nitsche, Pedro Henrique Ortunio e Thiago Bodnar

Dados e onde está cada coisa no repositório

- **Amostra avaliada:** 430 filmes do TMDB (4 gêneros × 3 períodos), dos quais **428 têm sinopse em português**. Todas as métricas de agrupamento, busca, recomendação e classificação foram calculadas nessa amostra, como o enunciado permite, porque ler e anotar milhares de sinopses à mão é inviável.
- **Catálogo do site:** 5.525 sinopses de 18 gêneros, coletadas pelo mesmo pipeline. Ele é usado pela busca e pela recomendação do site e, neste trabalho, como **dados novos** para testar o classificador (questão 4).
- **Críticas:** 1.859 críticas de usuários em português, com a nota que o autor deu ao filme (questão 5).
- **Oito representações:** BoW e TF-IDF, cada um sem pontuação e sem stopwords; Word2Vec CBOW e skip-gram (NILC); BERTimbau; e um BERT de sentença (paraphrase-multilingual-MiniLM).
- **Código:** backend/src/app/, uma pasta por tarefa. **Resultados:** data/, cada pasta com manifesto e hashes SHA-256. **Este documento e os scripts que o geram:** docs/entregas/unidade-3/. Para rodar o site: docs/tecnico/rodar-o-site.md.

1) Atividades realizadas

	BoW	**TF-IDF**	**Word2Vec**	**BERT**
Clusterização + PCA e visualização	✓	✓	✓	✓
Busca e recomendação	✓	✓	✓	✓
Classificação	✓	✓	✓	✓

Observações sobre a tabela:

- **Variantes:** BoW e TF-IDF foram testados sem pontuação e sem stopwords. Word2Vec, em CBOW e skip-gram. BERT, em dois modelos: o BERTimbau (BERT pré-treinado em português) e um BERT de sentença (MiniLM), treinado para comparar frases.
- **PCA:** a projeção 2D usa TruncatedSVD, o equivalente ao PCA para matrizes esparsas, que nas lexicais é a LSA. Ela foi aplicada a todas as representações.
- **Classificação:** os rótulos vieram prontos, os gêneros que o TMDB atribui a cada filme. Além da regressão logística, testamos Naive Bayes, SVM, floresta aleatória e kNN, e um modelo de linguagem sem treino, o Jev.

Tarefa	**Situação**
Análise de sentimento	(X) Foi realizada ( ) Não foi realizada
Reconhecimento de Entidades Nomeadas	(X) Foi realizado ( ) Não foi realizado
Extração de Relações	(X) Foi realizada ( ) Não foi realizada

2) Clusters: qual representação e quantos clusters

Aplicamos o K-Means (k-means++, 10 inicializações, semente fixa) às linhas com norma L2 de cada uma das oito representações, para k de 2 a 10. Medimos a forma dos grupos com métricas **intracluster** (distância de cosseno média de cada sinopse ao centroide do próprio grupo) e **intercluster** (distância de cosseno média entre os centroides), além de três índices que combinam as duas: a silhueta, o Davies-Bouldin e o Calinski-Harabasz. Também comparamos os grupos com os gêneros do TMDB (ARI, NMI e pureza), usando os 325 filmes de um único gênero. Código: backend/src/app/clustering/sweep.py; resultados: data/agrupamento/tmdb_2026-09-12/.

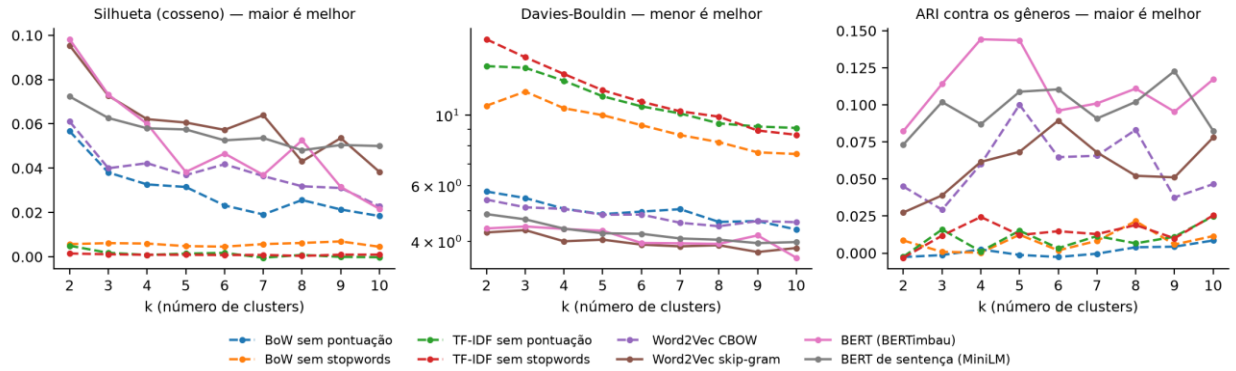


Figura 1 — Varredura de k: as métricas internas (silhueta e Davies-Bouldin) e a concordância com os gêneros (ARI).

Tabela 1 — Métricas com k = 4 (o número de gêneros da coleta)

Representação	Intra: dist. ao centroide	Inter: dist. entre centroides	Silhueta	Davies-Bouldin	Calinski-Harabasz	ARI	Pureza
BoW sem pontuação	0,409	0,156	0,033	5,06	9,1	0,002	31,7%
BoW sem stopwords	0,812	0,539	0,006	10,51	2,0	0,000	29,8%
TF-IDF sem pontuação	0,751	0,205	0,001	12,83	1,4	0,001	31,4%
TF-IDF sem stopwords	0,854	0,559	0,001	13,47	1,3	0,024	35,1%
Word2Vec CBOW	0,276	0,086	0,042	5,06	10,0	0,060	40,3%
Word2Vec skip-gram	0,230	0,097	0,062	4,00	15,1	0,062	41,2%
BERT (BERTimbau)	0,082	0,024	0,060	4,37	13,8	0,144	48,9%
BERT de sentença (MiniLM)	0,450	0,276	0,058	4,38	12,7	0,087	44,6%

Interpretação das métricas intra e intercluster:

- **Não há grupos naturais bem separados.** A silhueta fica abaixo de 0,10 em todas as representações: as sinopses formam uma nuvem contínua, e não ilhas. Nas lexicais (BoW e TF-IDF), a silhueta é praticamente zero (0,001 a 0,033 com k = 4) e o Davies-Bouldin é alto (5,1 a 13,5), contra cerca de 4 nas densas. Com vetores esparsos de milhares de dimensões, quase todas as sinopses ficam a distâncias parecidas umas das outras.
- **As distâncias só se comparam dentro de uma mesma representação.** O BERTimbau tem grupos compactos (distância ao centroide de 0,082), mas centroides próximos entre si (0,024): os vetores dele ocupam uma região estreita do espaço. O MiniLM tem distâncias maiores nos dois sentidos (0,450 e 0,276). Por isso não comparamos representações pela distância absoluta, e sim pela silhueta e pelo Davies-Bouldin, que são relativos.
- **As métricas internas se contradizem sobre k.** A silhueta e o Calinski-Harabasz preferem k = 2 em quase todas as representações, e o Davies-Bouldin melhora sempre com mais grupos (melhor k = 8 a 10). Isso é típico quando não há estrutura forte: dividir em dois maximiza a separação, e dividir em muitos reduz a dispersão dentro de cada grupo. As métricas internas, sozinhas, não indicam o número de grupos.
- **Também não há cotovelo na inércia.** A cada k a mais, a inércia cai só 0,3% no TF-IDF e de 1% a 3% nas densas, de forma suave, sem um ponto em que a queda pare de repente.

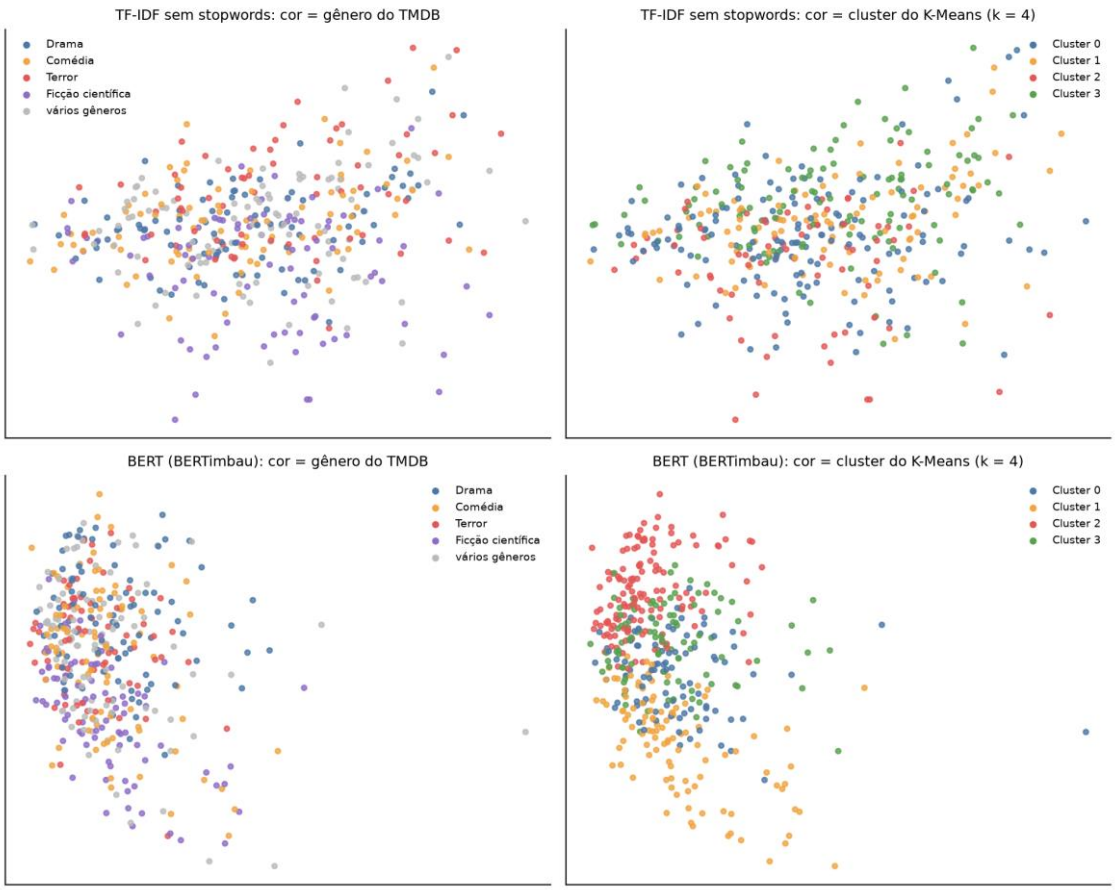


Figura 2 — Projeção 2D (TruncatedSVD) das 428 sinopses, colorida pelo gênero (esquerda) e pelo cluster com k = 4 (direita). Em cima, TF-IDF sem stopwords; embaixo, BERTimbau.

Leitura dos grupos. Para cada grupo, listamos os termos de maior peso médio no TF-IDF e os três filmes mais próximos do centroide:

Tabela 2 — Grupos do BERTimbau com k = 4

Grupo (BERTimbau, k = 4)	Tamanho	Termos mais característicos	Filmes mais próximos do centroide
Grupo 0	88	grupo, vírus, cidade, está, missão, terra	Premonição 5; A Morte do Demônio; Terror em Silent Hill
Grupo 1	106	peter, ser, precisa, mundo, está, vilão	Thor: Amor e Trovão; Mad Max: Estrada da Fúria; Os Vingadores: The Avengers
Grupo 2	136	casa, não, família, está, anos, amigos	Up: Altas Aventuras; 365 Dias: Hoje; Os Garotos Perdidos
Grupo 3	98	jovem, durante, ser, anos, polícia, guerra	O Grande Lebowski; Um Sonho de Liberdade; Fim dos Dias

- **BERTimbau, k = 4:** os grupos têm tema claro. São eles: **ameaça coletiva** (terror e ficção científica, com "grupo", "vírus", "missão"); **super-heróis** ("Peter", "vilão", *Thor*, *Vingadores*); **família, casa e amigos** (comédia e drama, como *Up*); e **drama de polícia, prisão e guerra** (*Um Sonho de Liberdade*). Um grupo é dominado pelo drama (61 dos 98 filmes), e outro mistura terror (50) e ficção científica (45).
- **BERTimbau, k = 5:** o grupo de ameaça coletiva se divide em **fim do mundo** (O Exterminador do Futuro 2: O Julgamento Final; O Predador; 2012) e **terror de grupo** (A Morte do Demônio; Terror em Silent Hill; Premonição 5), uma divisão que faz sentido para quem lê as sinopses. Com k = 5, o ARI se mantém em 0,144, e a pureza sobe de 48,9% para 52,6%.
- **TF-IDF sem stopwords, k = 4:** os grupos seguem palavras isoladas: um de "morte" e "família" (O Chamado; Extermínio 2; Premonição 5), um de "amor" e "juntos" (romances) e um de "casa" e "amigos". Os temas são legíveis, mas cortam os gêneros ao acaso (ARI de 0,024), e a projeção 2D é uma única nuvem, sem regiões de cor.

Conclusão. O **BERTimbau** gerou os clusters mais representativos, com o maior ARI (0,144), a maior pureza e grupos com temas reconhecíveis na leitura. O MiniLM vem em segundo (ARI de 0,123 com k = 9), e as lexicais quase não se relacionam com os gêneros. A quantidade que melhor expressou as características originais dos dados foi **k = 4 a 5**: o ARI do BERTimbau tem o pico nesses dois valores, e k = 4 coincide com os quatro gêneros da coleta. Ainda assim, os grupos refletem mais o **tema da história** (ameaça, heróis, família, polícia) do que o gênero, e a semelhança com os gêneros é fraca. Para separar gêneros, a classificação supervisionada (questão 4) é muito melhor: com o mesmo BERTimbau, o ARI sobe de 0,13 para 0,37.

3) Busca: qualidade dos top-3 e top-5

Escrevemos 20 consultas como um usuário digitaria e marcamos os filmes relevantes de cada uma **lendo as 428 sinopses antes de rodar qualquer algoritmo**. Para cada representação, a busca ordena as sinopses pelo cosseno com a consulta. A combinação usada no site soma 0,3 × o cosseno do TF-IDF e 0,7 × o do MiniLM, cada um dividido pelo maior cosseno da própria representação.

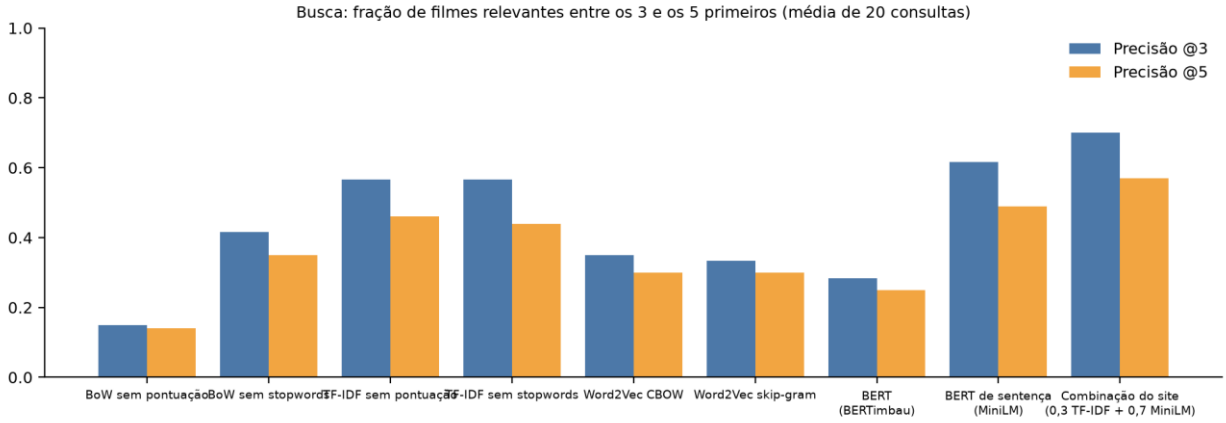


Figura 3 — Precisão @3 e @5 média nas 20 consultas anotadas.

Tabela 3 — Precisão nos 3 e nos 5 primeiros (média das 20 consultas)

Representação	Precisão @3	Precisão @5
BoW sem pontuação	15,0%	14,0%
BoW sem stopwords	41,7%	35,0%
TF-IDF sem pontuação	56,7%	46,0%
TF-IDF sem stopwords	56,7%	44,0%
Word2Vec CBOW	35,0%	30,0%
Word2Vec skip-gram	33,3%	30,0%
BERT (BERTimbau)	28,3%	25,0%
BERT de sentença (MiniLM)	61,7%	49,0%
Combinação do site (0,3 TF-IDF + 0,7 MiniLM)	70,0%	57,0%

Tabela 4 — Consulta "astronautas perdidos no espaço lutando para sobreviver" (6 relevantes). Tema concreto, com palavras que aparecem nas sinopses.

Representação	5 primeiros (✓= relevante)
TF-IDF sem stopwords	✓O Enigma do Horizonte; ✓Interestelar; ✗Top Gun - Ases Indomáveis; ✗Entre Montanhas; ✓Aliens: O Resgate
Word2Vec skip-gram	✗X-Men: Dias de um Futuro Esquecido; ✗Entre Montanhas; ✓Perdido em Marte; ✗S.O.S.: Tem um Louco Solto no Espaço; ✓O Enigma do Horizonte
BERT (BERTimbau)	✗X-Men: Dias de um Futuro Esquecido; ✓Perdido em Marte; ✗O Segredo do Abismo; ✓Alien: Romulus; ✗Moana 2
BERT de sentença (MiniLM)	✓Alien: Romulus; ✓Interestelar; ✓Perdido em Marte; ✓O Enigma do Horizonte; ✗S.O.S.: Tem um Louco Solto no Espaço
Combinação do site (0,3 TF-IDF +	✓O Enigma do Horizonte; ✓Interestelar; ✓Aliens: O Resgate; ✓Alien: Romulus; ✗Entre Montanhas

0,7 MiniLM)	

Tabela 5 — Consulta "família aterrorizada por espíritos em uma casa assombrada" (7 relevantes). Tema concreto de terror.

Representação	5 primeiros (✓= relevante)
TF-IDF sem stopwords	✓Invocação do Mal 2; ✓Os Outros; ✓Invocação do Mal; ✓Sobrenatural; ✗Uma Noite Alucinante: A Morte do Demônio
Word2Vec skip-gram	✗Hereditário; ✗Parasita; ✓Sobrenatural; ✓Os Outros; ✗Patos!
BERT (BERTimbau)	✓Invocação do Mal; ✓Invocação do Mal 2; ✗Um Lugar Silencioso; ✓Sobrenatural: A Última Chave; ✗ Premonição 6: Laços de Sangue
BERT de sentença (MiniLM)	✗Um Lugar Silencioso; ✗A Morte do Demônio; ✗Hereditário; ✓Os Fantasmas se Divertem; ✓Os Outros
Combinação do site (0,3 TF-IDF + 0,7 MiniLM)	✓Invocação do Mal 2; ✓Os Outros; ✓Invocação do Mal; ✗Hereditário; ✗Um Lugar Silencioso

Tabela 6 — Consulta "filme sobre simulação da realidade" (1 relevantes). Tema abstrato: só Matrix é relevante, e nenhuma sinopse fala em "simulação da realidade".

Representação	5 primeiros (✓= relevante)
TF-IDF sem stopwords	✗O Dublê; ✗Anaconda; ✗Holocausto Canibal; ✗A Iniciação; ✗Free Guy: Assumindo o Controle
Word2Vec skip-gram	✗Free Guy: Assumindo o Controle; ✗Anaconda; ✗O Dublê; ✗A Serbian Film - Terror sem Limites; ✓ Matrix
BERT (BERTimbau)	✗Uma Odisséia Chinesa: Parte Dois – Cinderela; ✗Meninas Malvadas; ✗Frankenstein; ✗Contra o Tempo; ✗A Serbian Film - Terror sem Limites
BERT de sentença (MiniLM)	✗Free Guy: Assumindo o Controle; ✓Matrix; ✗A Entidade; ✗A Bruxa de Blair; ✗O Chamado
Combinação do site (0,3 TF-IDF + 0,7 MiniLM)	✗Free Guy: Assumindo o Controle; ✓Matrix; ✗Kung Fu Panda; ✗Contato; ✗Avatar

Tabela 7 — Consulta "comédia romântica leve sobre um casal que se apaixona" (6 relevantes). Tom e gênero, difíceis para o ranking.

Representação	5 primeiros (✓= relevante)
TF-IDF sem stopwords	✓10 Coisas Que Eu Odeio em Você; ✗Acompanhante Perfeita; ✗Invocação do Mal 4: O Último Ritual; ✗ Ted 2; ✗Cinquenta Tons de Liberdade
Word2Vec skip-gram	✗A Morte lhe Cai Bem; ✗A Centopéia Humana 2; ✗Cisne Negro; ✗A Serbian Film - Terror sem Limites; ✗ Titanic
BERT (BERTimbau)	✗9 Canções; ✗A Iniciação; ✗Possessão; ✓O Dublê; ✓Dilwale vai levar a noiva
BERT de sentença (MiniLM)	✗Infidelidade; ✗Cinquenta Tons de Liberdade; ✓La La Land: Cantando Estações; ✗After: Depois do Desencontro; ✗Midsommar: O Mal Não Espera a Noite
Combinação do site (0,3 TF-IDF + 0,7 MiniLM)	✗Cinquenta Tons de Liberdade; ✗Infidelidade; ✗Acompanhante Perfeita; ✓10 Coisas Que Eu Odeio em Você; ✗Midsommar: O Mal Não Espera a Noite

Análise crítica:

- **Temas concretos funcionam bem.** Em "astronautas perdidos no espaço", o MiniLM acerta 4 dos 5 primeiros, e a combinação também (*O Enigma do Horizonte*, *Interestelar*, *Aliens*, *Alien: Romulus*). Em "casa assombrada", o TF-IDF acerta 4 de 5 (*Invocação do Mal* 1 e 2, *Os Outros*, *Sobrenatural*), porque as sinopses usam as mesmas palavras da consulta. O BERTimbau acerta 3, mas erra com *Um Lugar Silencioso*, que é terror sem casa assombrada.
- **Temas abstratos e de tom falham.** Em "filme sobre simulação da realidade", as lexicais trazem *O Dublê* e *Anaconda*, que só têm a palavra "filme" em comum. O MiniLM põe *Matrix* em 2º, depois de *Free Guy*, que se passa num jogo simulado e provavelmente é relevante, embora não tenha sido anotado. Em "comédia romântica leve", todos erram quase tudo: o tom "leve" não está escrito nas sinopses.
- **Cada família de representação erra de um jeito.** O TF-IDF exige a palavra exata, e "possessão demoníaca e exorcismo" devolve só 2 filmes, os únicos com essas palavras. O MiniLM entende paráfrases, mas às vezes troca o tema por um vizinho. O BERTimbau e o Word2Vec, que fazem a média de vetores de palavras ou de tokens,

ficam com a pior precisão: o vetor médio perde o sentido da frase, e o BERTimbau não foi treinado para comparar frases.

- **Utilizável num contexto real?** Para temas concretos, sim: na combinação, **70% dos 3 primeiros são relevantes**, e em 100% das consultas há ao menos um relevante entre os 5 primeiros. Para uma busca de produto, falta uma nota mínima, porque hoje a página sempre é completada com filmes pouco relacionados. Também falta tratar tom e gênero, o que no site é feito pelas regras de filtro, e não pelo ranking.
- **Combinação e melhorias feitas.** Primeiro testamos as combinações de 2 a 4 representações, com pesos e por posição (RRF). Escolhemos 0,3 × TF-IDF + 0,7 × MiniLM, que junta a palavra exata com o sentido, e o MAP subiu de 0,560 (MiniLM sozinho) para 0,613. Depois, a consulta passou a perder as palavras de pedido ("quero", "filmes sobre") e a recuperar acentos ("saude" → "saúde"), e o MAP foi a 0,627. No site, a busca procura num catálogo de 5.525 filmes, e regras extraem gênero, período e nota da frase como filtros.
- **Melhorias possíveis:** uma nota mínima calibrada nas consultas anotadas, um modelo de sentença maior, a busca também por elenco e diretor, e a avaliação com usuários reais, já que as 20 consultas foram escritas e julgadas pela própria equipe.

Trecho de código — combinação das representações (backend/src/app/search/hybrid.py)

```
def rank(self, text: str) -> list[tuple[int, float]]:
    """Pares (id, pontuação) com pontuação positiva, em ordem decrescente e, no empate, por id."""
    text = prepare_query(text, self.restorer)
    combined = np.zeros(len(self.corpus.ids))
    for representation, weight in self.members:
        ranked = search(representation, self.corpus, text).ranked
        if not ranked:
            continue
        top = ranked[0][1]
        for movie_id, score in ranked:
            combined[self._rows[movie_id]] += weight * score / top
    order = sorted((row for row in range(len(combined)) if combined[row] > 0), key=lambda row: (-
combined[row], self.corpus.ids[row]))
    return [(self.corpus.ids[row], float(combined[row])) for row in order]
```

Exemplo da limpeza da consulta: "filmes sobre saude mental" → "saude mental" (e o acento é recuperado pelo vocabulário: "saúde mental").

Recomendação. Na mesma amostra, a recomendação mostra os 5 filmes de sinopse mais parecida. A precisão @5 por gênero foi de 63,6% (BERTimbau) contra 37,9% ao acaso. No site, a ficha de cada filme mostra os 5 parecidos no catálogo: *Matrix* → *13º Andar* e as continuações de *Matrix*; *Toy Story* → *Lightyear*, *Toy Story 3*.

4) Classificação

Sim, foi possível treinar um classificador. Os rótulos vieram prontos: os gêneros que o TMDB atribui a cada filme, entre Drama, Comédia, Terror e Ficção científica. Montamos duas tarefas: **multiclasse**, com as 325 sinopses de um único gênero, e **multirrótulo**, com todas as que têm algum dos quatro gêneros. Cada representação alimenta uma regressão logística com classes de peso balanceado. O parâmetro C é escolhido dentro do próprio treino, e a avaliação usa validação cruzada em 5 dobras.

Tabela 8 — F1 macro na validação cruzada (multiclasse: 325 sinopses; multirrótulo: todas com algum dos 4 gêneros)

Representação	Reg. logística (multiclasse)	Reg. logística (multirrótulo)	Naive Bayes	SVM linear	Floresta aleatória	kNN
Referência (classe mais frequente)	10,7%	20,4%	—	—	—	—
BoW sem pontuação	46,1%	54,4%	59,1%	47,5%	44,2%	28,2%
BoW sem stopwords	56,4%	57,6%	61,3%	56,1%	47,4%	53,3%
TF-IDF sem pontuação	59,3%	58,0%	60,1%	60,4%	43,5%	53,3%
TF-IDF sem stopwords	59,2%	60,0%	58,9%	59,4%	49,4%	53,3%
Word2Vec CBOW	67,6%	68,3%	—	66,5%	60,5%	61,8%
Word2Vec skip-gram	71,0%	71,1%	—	70,3%	65,4%	61,1%

BERT (BERTimbau)	70,2%	69,8%	—	70,0%	68,2%	65,2%
BERT de sentença (MiniLM)	66,1%	66,8%	—	67,8%	66,9%	67,7%

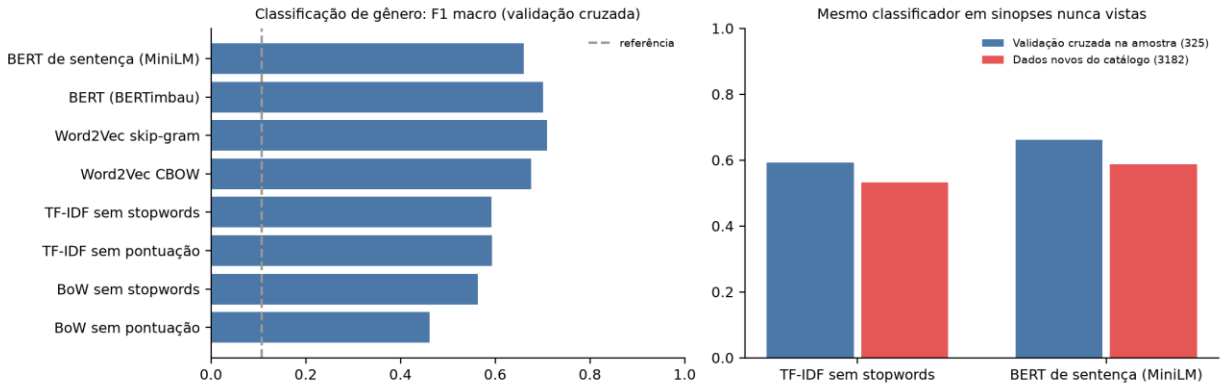


Figura 4 — À esquerda, F1 macro de cada representação. À direita, o mesmo classificador aplicado a sinopses que ele nunca viu.

Comportamento com dados novos. Testamos o classificador em **dados novos**, que ele nunca viu no treino:

- **Filmes do catálogo fora da amostra.** O classificador foi treinado nas 325 sinopses da amostra e aplicado às **3182 sinopses do catálogo do site que não estão na amostra** e têm um único dos quatro gêneros. Com o MiniLM, a acurácia foi de **63,1%** e o F1 macro de **58,7%**, contra 66,1% na validação cruzada. Com o TF-IDF, os valores foram 57,4% e 53,3%, contra 59,2%. A queda é moderada (6 a 7 pontos) e esperada: o catálogo é mais variado, com filmes menos populares e de outros gêneros secundários, e o TF-IDF sofre mais porque muitas palavras novas ficam fora do vocabulário do treino.
- **F1 por gênero nos dados novos (MiniLM):** Drama 72,5%, Comédia 54,2%, Terror 51,6%, Ficção científica 56,3%. Nos dados novos, terror e comédia são os mais difíceis; na validação cruzada, a comédia era o pior.
- **Na tela do site,** a aba "Classificar sinopse" classifica qualquer texto digitado.

Alguma representação favorece classificações mais precisas? Sim:

- **As densas pré-treinadas vencem as lexicais:** Word2Vec skip-gram (71,0%) e BERTimbau (70,2%) ficam cerca de 11 pontos acima do TF-IDF (59,2%). Com só 325 exemplos, o vocabulário do treino é pequeno, e os vetores pré-treinados trazem conhecimento de fora: "fantasma" e "espírito" ficam próximos, mesmo sem aparecer juntos no treino.
- **Skip-gram e BERTimbau empatam** dentro da variação entre as dobras. O MiniLM fica um pouco abaixo, mas foi o escolhido para a tela porque o site já o carrega para a busca.
- **Remover stopwords ajuda o BoW** (de 46,1% para 56,4%), mas quase não muda o TF-IDF, cujo idf já reduz o peso das palavras comuns.

Modelos de linguagem e modelos de decisão. Usamos os dois:

- **Modelo de linguagem sem treino (Jev, da TypeSafe AI, Aula 8):** o Jev recebe a sinopse e perguntas tipadas ("qual é o gênero principal?" e "este filme é de terror?"), sem ver nenhum exemplo rotulado. Nos mesmos 120 filmes, acertou **85,0%** do gênero principal, contra 56,0% do TF-IDF com regressão logística treinado no restante da amostra. Ele é bem melhor, mas cada classificação é uma chamada paga a um serviço externo. Por isso o site usa a regressão logística.
- **Modelos de decisão:** além da regressão logística, comparamos Naive Bayes, SVM linear, **floresta aleatória** (um conjunto de árvores de decisão) e kNN nas mesmas dobras (Tabela acima). A floresta aleatória ficou abaixo da regressão logística em sete das oito representações; só no MiniLM ficou ligeiramente acima (66,9% contra 66,1%). Com centenas de exemplos e centenas ou milhares de dimensões, as árvores dividem os dados em regiões pequenas demais e tendem a generalizar pior que um classificador linear. O Naive Bayes, por outro lado, foi o melhor no BoW (61,3% contra 56,4%), porque modela diretamente contagens de palavras.
- **Representações de modelos de linguagem:** o BERTimbau e o MiniLM são modelos de linguagem usados como extratores de vetores (congelados), com a regressão logística por cima.

5) Análise de sentimentos, NER e extração de relações

Sim, as três se aplicam, mas a dados diferentes:

- **Análise de sentimentos:** as **sinopses** não têm opinião, então não há sentimento a medir nelas. Por isso coletamos as **críticas de usuários do TMDB**, que vêm com a nota de 0 a 10 que o próprio autor deu ao filme. Isso dá texto e rótulo juntos, sem anotação manual, como havíamos proposto na Unidade 1.
- **NER e relações:** as sinopses são ricas em nomes de personagens, lugares e organizações, e descrevem ações ("Andy Dufresne é condenado por um crime"). Usamos o spaCy pt_core_news_sm e as regras de dependência do notebook da Aula 9.

Análise de sentimentos

Foram 1859 críticas em português, de 1634 filmes. As críticas com nota ≤ 4 são negativas (414), as com nota ≥ 7 são positivas (1008), e as do meio ficam só na previsão da nota. Testamos as oito representações com regressão logística (polaridade) e Ridge (nota), em 5 dobras, mantendo as críticas de um mesmo filme na mesma dobra. Os transformers leem a crítica inteira, em partes que cabem no modelo.

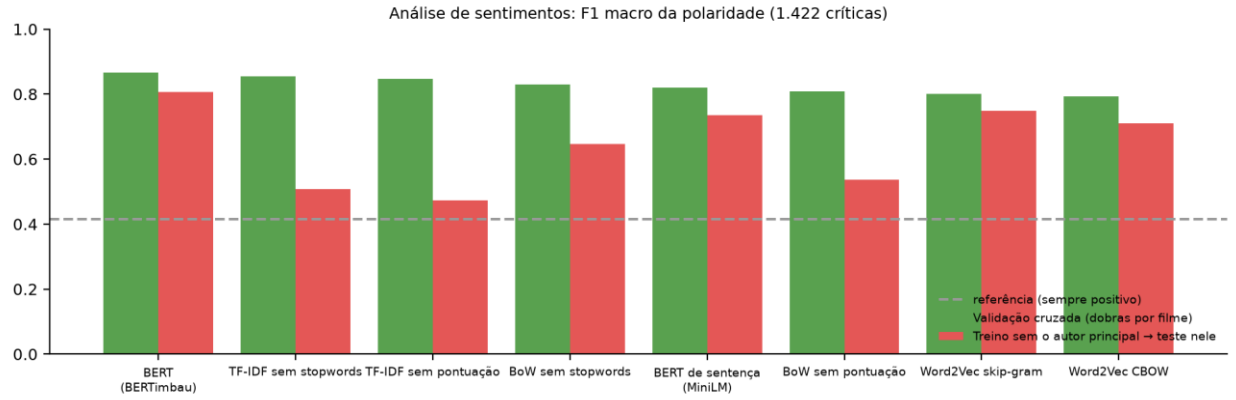


Figura 5 — F1 macro da polaridade: validação cruzada e teste entre autores.

Tabela 9 — Polaridade e nota prevista das críticas

Representação	F1 macro	Acurácia	Erro médio da nota	Treino sem o autor principal → teste nele
Referência (classe mais frequente)	41,5%	70,9%	1,98 (média)	—
BERT (BERTimbau)	86,7%	88,7%	1,33	80,8%
TF-IDF sem stopwords	85,6%	88,5%	1,37	50,7%
TF-IDF sem pontuação	84,7%	87,8%	1,36	47,4%
BoW sem stopwords	83,0%	86,1%	1,40	64,7%
BERT de sentença (MiniLM)	82,0%	84,4%	1,41	73,6%
BoW sem pontuação	80,9%	84,4%	1,40	53,8%
Word2Vec skip-gram	80,0%	82,6%	1,51	74,9%
Word2Vec CBOW	79,3%	82,0%	1,52	71,0%

- **O BERTimbau é o melhor** (F1 macro de 86,7%; erra a nota em 1,33 ponto em média). O TF-IDF fica logo atrás (85,6%): em críticas, palavras de opinião como "excelente", "gostei", "pior" e "desinteressante" já carregam boa parte do sentimento.
- **Um autor escreveu 67% das críticas.** Treinando sem ele e testando nele, o TF-IDF cai para 50,7%, e o BERTimbau mantém 80,8%. O TF-IDF decora o vocabulário de quem mais escreve; os vetores pré-treinados generalizam para outras pessoas.
- **Negação atrapalha todas as representações.** No TF-IDF, a acurácia é de 87,8% nas críticas com "não", "nem", "nunca" ou "sem", e de 95,2% nas sem. Na tela do site, "Não é um filme ruim…" sai negativo, e a ironia "Ótimo, mais uma continuação que ninguém pediu… Genial." sai positiva.

Reconhecimento de entidades nomeadas

Nas 428 sinopses, o spaCy reconheceu 1671 menções: 879 pessoas (PER), 491 lugares (LOC), 199 outras (MISC) e 102 organizações (ORG). Para medir sem anotar à mão, usamos os **créditos do TMDB** (os 15 primeiros nomes do elenco, ator e personagem) como referência parcial. Quando um nome dos créditos aparece na sinopse, conferimos que categoria o NER deu a ele.

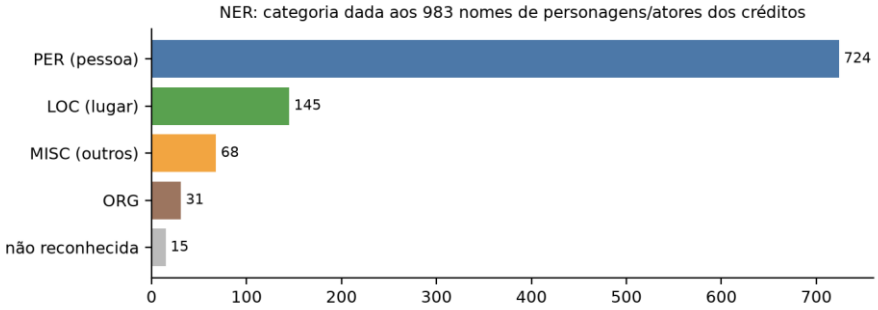


Figura 6 — Categoria dada pelo NER aos nomes de personagens e atores que aparecem nas sinopses.

- **O NER quase sempre encontra o nome**: 98,5% das 983 menções foram reconhecidas com alguma categoria.
- **Mas erra a categoria:** só 73,7% saem como pessoa. Personagens viram lugar ("Maximus" em *Gladiador*, "Mathilda" em *O Profissional*) ou MISC ("Forrest Gump"). O modelo foi treinado em notícias e conhece pouco os nomes de ficção, como havíamos previsto na Unidade 1.
- **Precisão estimada:** 81,6% das entidades PER têm um nome dos créditos. É um piso, porque apelidos como "Doc" não aparecem nos créditos.

Extração de relações

Aplicamos as regras do notebook da Aula 9: o sujeito (nsubj) de um verbo é ligado a cada complemento (obj e obl), e no obl a preposição entra na relação ("trabalhar_em"). Foram 1435 triplas: 732 com objeto direto, 615 com complemento preposicionado e 88 por uma regra a mais, em que um verbo coordenado herda o sujeito ("nasceu … e estudou …"). 63,5% das sentenças têm ao menos uma tripla.

Tabela 10 — Exemplos de triplas

Sinopse (trecho)	Tripla extraída
Matrix: "Thomas conhece os misteriosos Morpheus e Trinity…"	(Thomas, conhecer, Morpheus e Trinity) — correta
Akira: "…fez com que Tóquio fosse destruída em 1988."	(Tóquio, destruir_em, 1988) — correta
Drácula: "O vampiro Conde Drácula vem à Inglaterra…"	(vampiro Conde Drácula, vir_a, Inglaterra) — correta
Matrix: "…um sistema chamado Matrix, que manipula a mente das pessoas"	(que, manipular, mente das pessoas) — sujeito é pronome
A Outra Face: "…Sean Archer rastreia Troy, que embarcou em um avião…"	(…Sean Archer que embarcou em um avião…, rastrear, Troy) — sujeito misturado

- **Correferência é o maior limite:** 499 triplas (34,8%) têm "ele", "ela" ou "que" como sujeito, sem ligação ao personagem.
- **Poucas triplas ligam duas entidades** (2,2%). As sinopses descrevem ações de personagens sobre coisas, e não fatos entre entidades.
- **Conferência manual de 40 triplas sorteadas:** 27 de 40 corretas (67,5%). Os erros mais comuns foram sujeito ou objeto misturado com outra parte da frase e circunstâncias ("a partir de…", "desde logo") lidas como complemento. A marcação foi registrada pela equipe em config/entidades/conferencia_relacoes.json.

Trecho de código — regras de extração de relações (backend/src/app/entities/extraction.py)

```
    for complement in (t for t in verb.children if t.dep_ in COMPLEMENTS):
        preposition = next((t for t in complement.children if t.dep_ == "case"), None)
        relation = verb.lemma_
        if complement.dep_ == "obl" and preposition is not None:
            relation += "_" + normalize_preposition(preposition)
        rule = rule_for_subject or ("obl" if complement.dep_ == "obl" else "svo")
        for subject in subjects:
            triples.append(
```

```
                Triple(
                    make(subject),
                    relation,
                    make(complement),
                    sentence_of[verb.i],
                    rule,
                    entity_of(subject) is not None,
                    entity_of(complement) is not None,
                )
            )
return triples
```

No site: a aba "Analisar crítica" mostra o sentimento, a nota prevista e as palavras que mais pesaram. A ficha de cada filme mostra a sinopse com as entidades marcadas por cor e as relações extraídas.

Trecho de código — dobras que mantêm as críticas de um filme juntas (backend/src/app/sentiment/evaluation.py)

```
def grouped_folds(targets: np.ndarray, groups: Sequence[str], folds: int, random_state: int) -> Folds:
    """Dobras estratificadas pelo alvo em que nenhum grupo (filme) aparece em mais de uma dobra."""
    positions = np.arange(len(targets))
    splitter = StratifiedGroupKFold(n_splits=folds, shuffle=True, random_state=random_state)
    return list(splitter.split(positions, targets, np.asarray(groups)))
```

6) As técnicas auxiliam o projeto da Unidade 1?

Na Unidade 1, propusemos um **assistente de consulta a filmes em linguagem natural**: o usuário pergunta em português, o sistema descobre o que foi perguntado e sobre qual filme, consulta a API do TMDB e responde em linguagem natural. **Sim, as técnicas ajudaram**, e a maior parte da proposta virou parte do site:

Tabela 11 — Proposta da Unidade 1 × o que foi realizado

Proposta da Unidade 1	O que foi feito	Técnica
Extração de informação: separar a "moldura" da pergunta do nome do filme	A busca reconhece o título exato e tira as palavras de pedido ("quero", "me indica", "filmes sobre") antes de procurar por tema	Regras léxicas; preparação da consulta
Recuperação: ranquear o filme certo ("a evolução é vetorizar com TF-IDF e ranquear por cosseno")	Foi além: busca por tema nas sinopses com 0,3 × TF-IDF + 0,7 × MiniLM, num catálogo de 5.525 filmes (70% dos 3 primeiros relevantes)	TF-IDF, BERT de sentença, cosseno
Classificação da pergunta	O modo automático decide entre título, preferências (gênero, período, nota) e tema; a classificação treinada é de gênero das sinopses	Regras; regressão logística
"Outros": análise de sentimento em críticas, rotuladas pela nota do autor	Feita exatamente como proposto: 1.859 críticas, F1 macro de 86,7% e nota com erro médio de 1,33 ponto, na aba "Analisar crítica"	As 8 representações + regressão logística e Ridge
Reconhecimento de entidades ("léxico de títulos")	NER e relações nas sinopses, na ficha do filme	spaCy, dependências
Recomendação implícita em "me recomende algo parecido com Duna"	Filmes parecidos na ficha de cada filme	Cosseno no MiniLM
Chatbot de vários turnos ("e quem dirigiu?")	**Não feito:** o site responde a cada busca isoladamente, sem memória de conversa	—
Sumarização de sinopses	**Não feita**	—

- **As dificuldades previstas se confirmaram e foram tratadas.** A Unidade 1 previa o desbalanceamento das críticas ("72% são 7 ou mais"). Medimos 71% de positivas na polaridade e, como planejado, avaliamos com F1 macro e por classe, e não só com acurácia. Também previa que os nomes próprios de ficção prejudicariam os modelos, e o NER confirmou: um quarto dos personagens recebe outra categoria.
- **O que mais ajudou o assistente** foi a busca semântica. Uma pergunta como "astronautas perdidos no espaço" não tem título, e só a comparação de sentido entre a pergunta e as sinopses encontra *Interestelar* e *Perdido em Marte*. A classificação e o sentimento acrescentam informação que o TMDB não dá pronta: o gênero de um texto qualquer e o tom das críticas.

- **O que falta para o assistente completo** é a camada de diálogo, ou seja, a memória de contexto entre turnos e as respostas redigidas a partir dos dados da API. NER nas perguntas, e não só nas sinopses, ajudaria a delimitar o título dentro de frases longas, o principal obstáculo que apontamos na Unidade 1.

Uso de IA generativa

Fornecedor e modelo: Anthropic, **Claude Opus 5.5** (claude-opus-5-5), usado pela extensão **Claude Code** no VS Code, com acesso ao repositório. O assistente escreveu e testou código, rodou alguns experimentos e redigiu parte da documentação.

Prompts principais usados nesta etapa:

- "qual o melhor jeito para eu fazer o algoritmo de jev com base nesse exemplo"
- "certo, agora eu preciso decidir oq utilizar para fazer a busca no, tenho esses disponíveis qual você me indica a usar"
- "é possível fazer um sistema de recomendação com os algoritmos já implementadas?"
- "consigo usar algum desses Análise de sentimentos, Extração de Entidades Nomeadas e Extração de Relações para o trabalho?"
- “me de dicas de como fazer o Word2Vec e o algoritmo de BERT”